

Marabou 를 이용한 신경망 검증: MNIST 분류기의 지역적(Local) Robustness

Neural Network Verification with Marabou: Local Robustness of an MNIST Classifier
Formal Verification · SMT-based Analysis · L^∞ Robustness

초록 (Abstract)

본 보고서에서는 Marabou 의 SMT 기반 검증기를 사용하여 fully-connected MNIST 분류기의 지역적 (local) L^∞ robustness 를 100 개의 테스트 샘플과 0.01 부터 0.20 에 이르는 전체 ϵ sweep 에 대해 인증 (certify) 한다. 두 단계로 구성된 실험 설계에서는 먼저 $\epsilon = 0.05$ 에서 SAT 샘플을 식별하고(100 개 중 3 개), 이어서 robust 한 baseline 과 취약한 두 샘플의 robustness 변화 양상을 비교한다. 그 결과 샘플마다 다르게 나타나는 robustness, complete 검증에 내재된 SAT-UNSAT 런타임 비대칭성, 그리고 물리적으로 유효한 pixel 범위 clamping 이 검증 정확성에서 갖는 결정적 역할을 확인하였다.

1. 모델, 데이터셋, 검증 쿼리

784 → 64 → 32 → 10 구조의 fully-connected network(ReLU 활성화, 약 55,000 개 파라미터)를 Adam 과 cross-entropy loss 로 MNIST 에서 5 epoch 학습하여 약 97.5%의 test accuracy 를 얻었다. 학습한 모델은 Marabou 의 Python API 에서 사용하기 위해 ONNX(opset 11)로 export 하였다. 네트워크 규모는 의도적으로 작게 제한하였다. Marabou 의 complete SMT 기반 검증기는 ReLU 뉴런 수에 대해 지수적으로 확장되므로, 96 개의 hidden 뉴런 스택(64+32)은 적당한 ϵ 수준에서 1 분 이내의 쿼리를 보장할 수 있는 현실적인 상한선이다.

검증하려는 속성(query)은 지역적 robustness 이다. 올바르게 분류된 테스트 이미지 x (true label d)가 주어졌을 때, 반지름 ϵ 의 L^∞ ball 내에 있는 어떠한 perturbation 도 예측 클래스를 바꿀 수 없음을 증명한다.

형식적으로(Formally): $\forall x' \text{ s.t. } \|x' - x\|_\infty \leq \epsilon \Rightarrow \operatorname{argmax} f(x') = d$

Marabou 는 이 속성의 부정(negation)을 SAT 쿼리로 인코딩한다. 즉 ϵ -ball 내부에서 어떤 클래스 $j \neq d$ 가 d 보다 높은 점수를 받는 x' 를 탐색하고, 그 결과를 UNSAT(robustness 증명) 또는 SAT(구체적인 adversarial example)로 보고한다. 입력 bound 는 물리적으로 유효한 정규화 pixel 범위 $[-0.4242, 2.8215]$ 로 clamping 하였으며, 이 clamping 을 생략하면 큰 ϵ 에서 False SAT 가 발생한다.

실험은 두 단계로 진행하였다. Phase 1에서는 $\epsilon = 0.05$ 에서 100 개의 테스트 이미지를 스캔하여 SAT 샘플을 식별하였다. Phase 2에서는 대표 샘플 3 개에 대해 $\epsilon \in [0.01, 0.20]$ 구간을 sweep 하였다. 대표 샘플은 전 구간 UNSAT 인 baseline(idx=0, label 7)과 Phase 1 에서 발견한 두 SAT 샘플(idx=8, label 5; idx=33, label 4)이다.

2. 결과

2.1 Phase 1 — $\epsilon = 0.05$ 에서의 샘플 스캔

Phase 1에서는 $\epsilon = 0.05$ 에서 100 개 중 3 개의 SAT 샘플(인덱스 8, 33, 92)을 발견하였으며, 이는 robustness 가 네트워크 전체에 보편적인 속성이 아니라 샘플에 따라 달라지는 성질임을 확인해 준다. Phase 2 를 위해 다음 세 개의 대표 샘플을 선정하였다.

Sample Index	True Label	$\epsilon = 0.05$ Verdict	Role in Phase 2
idx = 0	7	UNSAT	All-UNSAT baseline
idx = 8	5	SAT → class 6	SAT sample (5→6 confusion)
idx = 33	4	SAT → class 0	SAT sample (4→0 confusion)

표 1. $\epsilon = 0.05$ 에서의 Phase 1 스캔 결과와 Phase 2에서의 역할. Adversarial target: idx=8 $\rightarrow$ class 6 (5 $\rightarrow$ 6 혼동), idx=33 $\rightarrow$ class 0 (4 $\rightarrow$ 0 혼동).

2.2 Phase 2 — 세 대표 샘플에 대한 전체 ϵ Sweep

Phase 2에서는 $\epsilon \in [0.01, 0.20]$ 구간에 대해 다음과 같은 3-way 비교 결과를 얻었다. 기호 $*$ 는 verdict가 처음으로 SAT로 전환되는 정확한 robustness 경계인 ϵ^* 를 나타낸다.

ϵ (norm.)	ϵ (raw /255)	idx=0 (label 7)	idx=8 (label 5)	idx=33 (label 4)
0.01	~ 0.8	UNSAT (0.4s)	UNSAT (0.5s)	UNSAT (0.5s)
0.02	~ 1.6	UNSAT (0.4s)	UNSAT (0.6s)	UNSAT (0.5s)
0.03	~ 2.4	UNSAT (0.5s)	SAT * (0.5s)	UNSAT (0.5s)
0.05	~ 4.0	UNSAT (0.5s)	SAT (0.8s)	SAT * (0.5s)
0.10	~ 8.1	UNSAT (0.9s)	SAT (0.9s)	SAT (0.6s)
0.15	~ 12.1	UNSAT (14.3s)	SAT (1.1s)	SAT (0.5s)
0.20	~ 16.2	UNSAT (300.5s)	SAT (0.6s)	SAT (0.5s)

표 2. Phase 2 전체 ϵ sweep. 초록 = UNSAT(증명 가능한 robust), 빨강 = SAT(adversarial example 발견). $*$ 는 최초 SAT 전환 지점(ϵ^*)을 표시한다.




그림 1. Marabou 지역적 robustness 검증 — 런타임 및 verdict 비교. MNIST FC (784 $\rightarrow$ 64 $\rightarrow$ 32 $\rightarrow$ 10, 96 ReLU 뉴런), 세 개의 테스트 샘플.

2.3 핵심 결과

세 가지 결과가 두드러진다.

첫째, robustness는 샘플마다 다르게 나타난다(sample-heterogeneous). 샘플 0(숫자 7)은 전체 sweep 구간에서 증명 가능하게 robust 하며, $\epsilon = 0.20$ (원시 pixel 기준 약 16/255)에서도 adversarial 입력이 존재하지

않는다. 반면 샘플 8 과 33 은 각각 $\epsilon^* \approx 0.03$, $\epsilon^* \approx 0.05$ 에서 뚜렷한 robustness 경계를 가지며, 이는 두 샘플의 decision boundary 가 nominal 입력에 비정상적으로 가깝게 위치함을 시사한다.

둘째, SAT-UNSAT 런타임 비대칭성은 branch-and-bound 탐색 구조를 그대로 반영한다. UNSAT 는 solver 가 2^{96} 규모의 case-split 트리 전체를 소진해야 하므로 지수적인 런타임 증가를 보인다($\epsilon \leq 0.11$ 까지는 1 초 미만이다가 이후 $6s \rightarrow 14s \rightarrow 26s \rightarrow 139s \rightarrow 300s$). 반면 SAT 는 첫 witness 를 발견하는 순간 종료되므로, 단 하나의 counterexample 만 찾으면 충분하여 $\epsilon = 0.20$ 에서도 1 초 미만이다. 이 비대칭성은 Marabou 고유의 현상이 아니라 NP-hard 문제에 대한 complete 검증에 본질적으로 내재된 성질이다.

셋째, 물리적 bounds clamping 을 제거하자 샘플 0 에서 $\epsilon = 0.15$ 에 spurious SAT 가 발생하였고, $\epsilon = 0.12$ 의 런타임이 6s 에서 248s 로 부풀어 올랐다(40 배 느려짐). solver 가 $[-0.4242, 2.8215]$ 범위 밖의 입력까지 탐색하면서 물리적으로 불가능한 adversarial example 을 찾아낸 것이다. 유효한 pixel 범위를 강제하면 이 실패 모드는 완전히 사라진다.

참고: 물리적 Bounds Clamping 은 정확성 요건이다

Formal verification 은 ‘명시된 문제(problem as stated)’에 대해서만 soundness 를 보장한다. 도메인 지식(유효 pixel 범위)이 없으면 SMT solver 는 수학적으로는 가능하지만 물리적으로는 의미 없는 영역까지 충실히 탐색하여 False SAT 를 만들어낸다. 입력 bound 를 $[-0.4242, 2.8215]$ 로 clamping 하는 것은 최적화가 아니라, 검증 문제를 올바르게 정의하는 일의 일부이다.

3. 논의: 강점과 한계

3.1 강점

(a) 완전성(Completeness). UNSAT 결과는 통계적 주장이나 공격을 찾는 데 실패했다는 경험적 사실이 아니라, 무조건적인(unconditional) 수학적 증명이다. 이는 공격이 특정 방향을 탐색하지 못해 adversarial example 을 놓칠 수 있는 gradient 기반 기법(FGSM, PGD)과 질적으로 다르다. 안전이 중요한(safety-critical) 시스템에서 이 차이는 타협할 수 없다.

(b) Counterexample 해석 가능성. 속성이 위반될 경우(SAT) Marabou 는 정확한 logit 값을 포함한 구체적인 입력 assignment 를 반환하므로 실패를 직접 들여다볼 수 있다. 이는 더 작은 perturbation 이 존재하지 않는다는 증명 없이 perturbed image 만 보고하는 공격 기반 기법보다 훨씬 실효성이 높다.

3.2 한계

(a) 확장성(Scalability). 이 96-뉴런 네트워크에서도 $\epsilon = 0.18$ 은 139 초가 걸렸다. branching factor 로 인해 최악의 경우 런타임이 $O(2^n)$ 으로 증가하므로, 수백 개를 넘는 뉴런을 가진 네트워크는 commodity hardware 에서 complete 검증이 사실상 불가능하다. 이는 Marabou 만의 한계가 아니라 문제 자체의 본질적 난이도이다(robustness verification 은 Σ_2^P -complete 이다).

(b) 탐색 공간 민감성. false-SAT 사례는 solver 가 주어진 제약 조건만큼만 신뢰할 수 있음을 보여준다. 도메인 지식(유효 pixel 범위)이 없으면 SMT solver 는 수학적으로는 가능하지만 물리적으로는 의미 없는 영역을 충실히 탐색한다. Formal verification 은 명시된 문제에 대해서만 soundness 를 보장하며, 문제를 올바르게 명시하는 책임은 전적으로 사용자에게 있다.

(c) 활성화 함수 지원. Complete 검증은 piecewise-linear 활성화를 요구한다. Sigmoid, GELU, layer normalization 을 사용하는 네트워크는 completeness 를 tractability 와 맞바꾸는 abstraction 기반 relaxation 이 필요하며, 이는 Marabou 를 현대의 transformer 기반 아키텍처에 적용하는 데 제약이 된다.